Manifesto per un'Intelligenza Artificiale Etica e Human-Centric

L'intelligenza artificiale (IA) rappresenta una delle più grandi opportunità del nostro tempo, ma anche una delle più grandi sfide. Se sviluppata e utilizzata in modo responsabile, l'IA può migliorare la qualità della vita, promuovere l'innovazione e risolvere problemi complessi. Tuttavia, senza un quadro etico solido e un controllo umano adeguato, rischia di amplificare disuguaglianze, minacciare i diritti fondamentali e compromettere la sicurezza delle nostre società.

Questo manifesto nasce con l'obiettivo di unire autorità accademiche, politiche e istituzionali in un impegno comune: **garantire che l'IA sia sviluppata e implementata in modo etico, trasparente e human-centric**. Chiediamo all'Unione Europea di adottare misure concrete che vadano oltre il rispetto del GDPR, includendo controlli rigorosi sulla sicurezza etica e decisionale dei sistemi di IA.

The Manifesto for an Ethical and Human-Centric Artificial Intelligence
Copyright (C) Alessandro Verna and Alvise Gottieri May 9 2025.

Permission is granted to copy, distribute and/or modify this document
under the terms of the Gnu Free Documentation License, Version 1.3

https://www.gnu.org/licenses/fdl-1.3.html#license-text or any later
version published by the Free Software Foundation;
with no Invariant Sections, no Front-Cover Texts, and no Back-Cover Texts.

Sommario Manifesto per un'Intelligenza Artificiale Etica e Human-Centric	1
1. Perché un Manifesto per un'IA Etica e Human-Centric?	
1.1 L'Impatto Trasformativo dell'IA	
1.1.1 Opportunità dell'IA	
1.1.2 Rischi dell'IA	5
1.2 Le Sfide Etiche dell'IA	5
1.2.1 Discriminazione e Bias	6
1.2.2 Privacy e Sorveglianza	6
1.2.3 Trasparenza e Responsabilità	6
1.2.4 Impatto Occupazionale	6
1.3 La Necessità di un Approccio Human-Centric	6
1.3.1 Supervisione Umana	6
1.3.2 Allineamento ai Valori Umani	6
1.3.3 Benessere Sociale e Ambientale	6
1.4 Il Nuovo Significato di Formazione delle Nuove Generazioni	7
1.4.1 Educazione all'IA	7
1.4.2 Adattamento Cognitivo	7
1.4.3 Formazione Continua	7
1.5 II Pericolo dell'Utilizzo dell'IA per Scopi Militari	8
1.5.1 Armi Autonome e Decisioni Letali	8
1.5.2 Violazione del Diritto Internazionale	8
1.5.3 Erosione del Controllo Umano	8
1.5.4 Necessità di un Controllo Umano Finale	8
1.5.5 Implicazioni per la Sicurezza Globale	9
2. I Principi Fondamentali del Manifesto	10
2.1 Supervisione Umana	10
2.1.1 Livelli di Supervisione	
2.1.2 Implicazioni Pratiche	10
2.1.3 Azioni Necessarie	
2.2 Sicurezza Etica e Decisionale	11
2.2.1 Meccanismi di Controllo	11

2.2.2 Implicazioni Pratiche	11
2.2.3 Azioni Necessarie	11
2.3 Trasparenza e Spiegabilità	11
2.3.1 Modelli Interpretabili	11
2.3.2 Implicazioni Pratiche	11
2.3.3 Azioni Necessarie	12
2.4 Equità e Non Discriminazione	12
2.4.1 Identificazione e Correzione dei Bias	12
2.4.2 Implicazioni Pratiche	12
2.4.3 Azioni Necessarie	12
2.5 Privacy e Protezione dei Dati	12
2.5.1 Minimizzazione dei Dati	12
2.5.2 Implicazioni Pratiche	13
2.5.3 Azioni Necessarie	13
2.6 Benessere Sociale e Ambientale	13
2.6.1 Impatto Sociale	13
2.6.2 Impatto Ambientale	13
2.6.3 Azioni Necessarie	13
2.7 Responsabilità e Tracciabilità	13
2.7.1 Meccanismi di Responsabilità	13
2.7.2 Implicazioni Pratiche	14
2.7.3 Azioni Necessarie	14
3. Verifica del Codice: Garantire Sicurezza Etica e Decisionale	15
3.1 Elementi di Sicurezza nel Codice	15
3.1.1 Robustezza Tecnica	15
3.1.2 Controlli Etici Integrati	15
3.1.3 Tracciabilità delle Decisioni	16
3.1.4 Spiegabilità	16
3.2 Processi di Verifica Indipendenti	16
3.2.1 Audit Regolari	17
3.2.2 Certificazioni Etiche	17
3.2.3 Linee Guida per gli Sviluppatori	18
3.2.4 Coinvolgimento delle Parti Interessate	18

3.2.5 Collaborazione Internazionale	19
3.3 La Minaccia dell'Accelerazionismo	19
3.3.1 Rischi dell'Accelerazionismo	19
3.3.2 Concorrenza Sleale e Mancanza di Standard	20
3.3.3 Impatto sulla Sicurezza Etica e Decisionale	20
3.3.4 Azioni Necessarie per Contrastare l'Accelerazionismo	21
4. Le Azioni Concrete per un'IA Etica e Human-Centric	22
4.1 Un Quadro Normativo Completo	22
4.1.1 Regolamenti Vincolanti	22
4.1.2 Standard Tecnici	22
4.1.3 Certificazioni Etiche	23
4.2 Collaborazione Globale	23
4.2.1 Forum Internazionali	23
4.2.2 Standard Globali	23
4.2.3 Condivisione di Risorse	24
4.3 Educazione e Consapevolezza	24
4.3.1 Programmi di Formazione	24
4.3.2 Campagne di Sensibilizzazione	24
4.3.3 Iniziative per il Pubblico	25
4.4 Partecipazione Pubblica	25
4.4.1 Panel Civici	25
4.4.2 Consultazioni Pubbliche	25
4.4.3 Meccanismi di Feedback	
5. Un Appello all'Azione	27
6. Conclusione	28

1. Perché un Manifesto per un'IA Etica e Human-Centric?

L'intelligenza artificiale (IA) è una delle tecnologie più transformative del nostro tempo, con il potenziale di rivoluzionare settori come la sanità, l'istruzione, l'economia e la governance. Tuttavia, il suo sviluppo solleva importanti questioni etiche che devono essere affrontate per garantire che l'IA sia utilizzata in modo responsabile e sostenibile. Questo manifesto nasce dalla necessità di unire autorità accademiche, politiche e istituzionali in un impegno comune: garantire che l'IA sia sviluppata e implementata in modo etico, trasparente e human-centric. Di seguito, approfondiamo le ragioni che rendono questo manifesto non solo necessario, ma urgente.

1.1 L'Impatto Trasformativo dell'IA

L'IA sta trasformando ogni aspetto della nostra società, offrendo opportunità senza precedenti per migliorare la qualità della vita, risolvere problemi complessi e promuovere l'innovazione. Tuttavia, questa trasformazione non è priva di rischi.

1.1.1 Opportunità dell'IA

- Miglioramento della Qualità della Vita: L'IA può rivoluzionare settori
 come la sanità, l'istruzione e i trasporti, offrendo soluzioni personalizzate
 e efficienti.
- **Soluzione di Problemi Globali**: L'IA può contribuire a risolvere problemi complessi, come il cambiamento climatico, la povertà e le disuguaglianze sociali.
- Innovazione Economica: L'IA può stimolare la crescita economica, creando nuovi posti di lavoro e opportunità di business.

1.1.2 Rischi dell'IA

- Amplificazione delle Disuguaglianze: Senza controlli adeguati, l'IA può amplificare le disuguaglianze esistenti, creando nuove forme di esclusione sociale ed economica.
- **Violazione dei Diritti Umani**: L'IA può essere utilizzata per violare i diritti fondamentali, come la privacy, la libertà di espressione e la non discriminazione.
- Perdita di Controllo: Senza supervisione umana, l'IA può prendere decisioni dannose o imprevedibili, con conseguenze potenzialmente disastrose.

1.2 Le Sfide Etiche dell'IA

Lo sviluppo e l'uso dell'IA sollevano importanti questioni etiche che devono essere affrontate per garantire che questa tecnologia sia al servizio dell'umanità.

1.2.1 Discriminazione e Bias

Gli algoritmi di IA possono perpetuare pregiudizi razziali, di genere o economici, amplificando disuguaglianze esistenti.

Esempio: Software di riconoscimento facciale con bias razziali, sistemi di reclutamento che discriminano le donne.

1.2.2 Privacy e Sorveglianza

L'IA raccoglie e analizza enormi quantità di dati personali, aumentando i rischi di abuso e sorveglianza di massa.

Esempio: Sorveglianza di massa da parte di governi autoritari, uso improprio dei dati da parte delle aziende.

1.2.3 Trasparenza e Responsabilità

Molti sistemi di IA sono "scatole nere", rendendo difficile comprendere come prendono decisioni che influenzano la vita delle persone.

Esempio: Decisioni opache in contesti critici come la sanità o la giustizia.

1.2.4 Impatto Occupazionale

L'automazione guidata dall'IA potrebbe eliminare milioni di posti di lavoro, creando nuove disuguaglianze sociali ed economiche.

Esempio: Perdita di posti di lavoro in settori come la manifattura, i trasporti e i servizi.

1.3 La Necessità di un Approccio Human-Centric

Un approccio human-centric all'IA significa mettere le persone al centro dello sviluppo e dell'uso di questa tecnologia, garantendo che sia al servizio dell'umanità e non il contrario.

1.3.1 Supervisione Umana

Gli esseri umani devono mantenere il controllo sulle decisioni dell'IA, con la possibilità di intervenire, correggere o disattivare i sistemi in caso di necessità.

Esempio: Modelli di supervisione come "Human-in-the-loop" e "Human-on-the-loop".

1.3.2 Allineamento ai Valori Umani

L'IA deve essere progettata per rispettare i diritti fondamentali e i valori etici, come la privacy, l'equità e la non discriminazione.

Esempio: Integrazione di principi etici nel codice e nei processi decisionali.

1.3.3 Benessere Sociale e Ambientale

L'IA deve contribuire al benessere della società e alla sostenibilità ambientale, promuovendo equità e riducendo gli impatti negativi.

Esempio: Applicazioni dell'IA per la riduzione delle emissioni di carbonio e la promozione dell'inclusione sociale.

1.4 Il Nuovo Significato di Formazione delle Nuove Generazioni

L'impatto cognitivo dell'IA sta trasformando il modo in cui le persone apprendono, pensano e interagiscono con il mondo. Questo richiede un nuovo approccio alla formazione delle nuove generazioni, che le prepari a vivere e lavorare in un mondo sempre più influenzato dall'intelligenza artificiale.

1.4.1 Educazione all'IA

Le nuove generazioni devono essere educate sui principi etici e di sicurezza dell'IA, per comprendere sia le opportunità che i rischi di questa tecnologia.

Programmi Scolastici: Integrare l'educazione all'IA nei programmi scolastici, dalla scuola primaria all'università.

Competenze Digitali: Insegnare competenze digitali avanzate, come la programmazione e l'analisi dei dati.

Pensiero Critico: Promuovere il pensiero critico e la capacità di valutare l'impatto sociale dell'IA.

1.4.2 Adattamento Cognitivo

L'IA sta cambiando il modo in cui le persone processano le informazioni e prendono decisioni. Questo richiede un adattamento cognitivo per evitare dipendenze tecnologiche e perdita di autonomia.

Bilanciamento Uomo-Tecnologia: Insegnare alle nuove generazioni a bilanciare l'uso della tecnologia con il pensiero autonomo e la creatività.

Consapevolezza Digitale: Promuovere la consapevolezza dei rischi cognitivi dell'IA, come la dipendenza da algoritmi e la perdita di privacy.

1.4.3 Formazione Continua

In un mondo in rapida evoluzione, la formazione non può limitarsi ai primi anni di vita. È essenziale promuovere la formazione continua per adattarsi alle nuove sfide e opportunità dell'IA.

Programmi di Aggiornamento: Creare programmi di formazione continua per lavoratori e cittadini, focalizzati sulle nuove tecnologie e competenze.

Apprendimento Permanente: Promuovere una cultura dell'apprendimento permanente, che valorizzi l'aggiornamento costante delle competenze.

1.5 Il Pericolo dell'Utilizzo dell'IA per Scopi Militari

L'uso dell'IA in contesti militari rappresenta una delle applicazioni più controverse e pericolose di questa tecnologia. Senza un controllo umano adeguato, l'IA può essere utilizzata per prendere decisioni autonome su target umani e civili, con conseguenze potenzialmente catastrofiche.

1.5.1 Armi Autonome e Decisioni Letali

Le armi autonome, conosciute anche come "robot killer", sono sistemi di IA in grado di identificare, selezionare e attaccare target senza intervento umano. Questo solleva gravi preoccupazioni etiche e legali.

Errori Irreversibili: Un sistema di IA potrebbe identificare erroneamente un civile come un bersaglio militare, causando vittime innocenti.

Escalation dei Conflitti: L'uso di armi autonome potrebbe accelerare i conflitti, rendendo più difficile il controllo e la de-escalation.

Responsabilità Opaca: Senza un controllo umano diretto, è difficile attribuire la responsabilità per le decisioni letali prese dall'IA.

1.5.2 Violazione del Diritto Internazionale

L'uso di armi autonome potrebbe violare i principi del diritto internazionale umanitario, come la distinzione tra combattenti e civili e il principio di proporzionalità.

Indiscriminazione: Un sistema di IA potrebbe non essere in grado di distinguere adeguatamente tra obiettivi militari e civili, portando a violazioni dei diritti umani.

Mancanza di Empatia: L'IA non ha la capacità di comprendere il contesto umano o di mostrare compassione, rendendola inadatta a prendere decisioni che coinvolgono la vita umana.

1.5.3 Erosione del Controllo Umano

L'uso autonomo dell'IA in contesti militari erode il controllo umano sulle decisioni critiche, trasferendo la responsabilità a macchine che non possono essere ritenute moralmente o legalmente responsabili.

Perdita di Autonomia: La delega di decisioni letali all'IA riduce il ruolo degli esseri umani nel processo decisionale, minando i principi etici e democratici.

Rischio di Abuso: Governi o gruppi armati potrebbero utilizzare armi autonome per scopi repressivi o per commettere crimini di guerra senza accountability.

1.5.4 Necessità di un Controllo Umano Finale

È essenziale che l'uomo mantenga l'ultima parola sulle decisioni che coinvolgono target umani e civili. Questo principio, noto come "meaningful human control", garantisce che le decisioni letali siano sempre soggette a valutazione e approvazione umana.

Divieto di Armi Autonome: Promuovere un divieto globale sullo sviluppo e l'uso di armi autonome che possano prendere decisioni letali senza controllo umano.

Regolamentazione Internazionale: Sviluppare trattati e accordi internazionali che limitino l'uso dell'IA in contesti militari e garantiscano il rispetto del diritto internazionale umanitario.

Supervisione Umana Obbligatoria: Implementare meccanismi che garantiscano che ogni decisione che coinvolga target umani e civili sia soggetta a supervisione e approvazione umana.

1.5.5 Implicazioni per la Sicurezza Globale

L'uso incontrollato dell'IA in contesti militari minaccia la sicurezza globale, aumentando il rischio di conflitti incontrollabili e di una corsa agli armamenti basata sull'IA.

Corsa agli Armamenti: I paesi potrebbero competere per sviluppare armi autonome sempre più avanzate, creando un'instabilità globale.

Proliferazione delle Armi: Le armi autonome potrebbero cadere nelle mani di gruppi armati non statali, aumentando il rischio di terrorismo e conflitti asimmetrici.

Diplomazia Preventiva: <u>Promuovere</u> il dialogo tra le nazioni per prevenire una corsa agli armamenti basata sull'IA.

Controlli sulle Esportazioni: Implementare controlli rigorosi sull'esportazione di tecnologie militari basate sull'IA.

2. I Principi Fondamentali del Manifesto

Proponiamo un quadro etico basato su sette principi fondamentali, che devono guidare lo sviluppo e l'implementazione dell'IA. Questi principi sono essenziali per garantire che l'IA sia al servizio dell'umanità, rispettando i diritti fondamentali e promuovendo il benessere sociale. Di seguito, approfondiamo ciascun principio in dettaglio.

2.1 Supervisione Umana

La supervisione umana è il principio cardine per garantire che l'IA rimanga uno strumento al servizio delle persone, e non il contrario. Questo principio richiede che gli esseri umani mantengano il controllo sulle decisioni dell'IA, con la possibilità di intervenire, correggere o disattivare i sistemi in caso di necessità.

2.1.1 Livelli di Supervisione

- **Uomo nel loop (Human-in-the-loop)**: In questo modello, un operatore umano supervisiona attivamente le decisioni dell'IA e può correggerle in tempo reale. Questo approccio è particolarmente importante in contesti critici, come la sanità o la giustizia.
- Uomo sopra il loop (Human-on-the-loop): L'IA opera in modo autonomo, ma un operatore umano può intervenire se il sistema commette errori o produce risultati inaccettabili. Questo modello è adatto per applicazioni come i veicoli autonomi.
- **Uomo fuori dal loop (Human-out-of-the-loop)**: L'IA agisce in modo completamente autonomo, senza intervento umano. Questo approccio è sconsigliato per applicazioni ad alto rischio, poiché riduce il controllo umano.

2.1.2 Implicazioni Pratiche

- Contesti Critici: In settori come la sanità, la sicurezza e la giustizia, la supervisione umana è essenziale per evitare errori potenzialmente letali o dannosi.
- **Responsabilità**: La supervisione umana garantisce che ci sia sempre una persona responsabile delle decisioni dell'IA, facilitando la tracciabilità e la correzione degli errori.

2.1.3 Azioni Necessarie

 Progettazione di Interfacce Umane: I sistemi di IA devono includere interfacce intuitive che permettano agli operatori umani di comprendere e intervenire facilmente. Formazione degli Operatori: Gli operatori umani devono essere adeguatamente formati per supervisionare e correggere i sistemi di IA.

2.2 Sicurezza Etica e Decisionale

La sicurezza etica e decisionale riguarda la capacità dell'IA di prendere decisioni allineate ai valori umani e ai diritti fondamentali, minimizzando i rischi di danni o violazioni.

2.2.1 Meccanismi di Controllo

- **Limitazione delle Decisioni**: I sistemi di IA devono essere configurati per evitare decisioni estreme o pericolose, come quelle che potrebbero violare i diritti umani.
- **Allineamento ai Valori Umani**: Il codice deve incorporare principi etici, come il rispetto della privacy, l'equità e la non discriminazione, in ogni fase del processo decisionale.

2.2.2 Implicazioni Pratiche

- Prevenzione dei Danni: Senza controlli etici, i sistemi di IA possono prendere decisioni dannose, come discriminazioni o violazioni della privacy.
- **Fiducia del Pubblico**: La sicurezza etica è essenziale per costruire fiducia nell'IA, favorendone l'adozione e l'integrazione nella società.

2.2.3 Azioni Necessarie

- **Integrazione di Controlli Etici**: Gli sviluppatori devono integrare meccanismi di controllo etico nel codice, come strumenti per rilevare e correggere bias.
- **Valutazioni di Rischio**: Ogni sistema di IA deve essere sottoposto a valutazioni di rischio per identificare potenziali violazioni etiche.

2.3 Trasparenza e Spiegabilità

La trasparenza e la spiegabilità sono essenziali per garantire che i processi decisionali dell'IA siano comprensibili e accessibili, anche per utenti non tecnici.

2.3.1 Modelli Interpretabili

- **Algoritmi Trasparenti**: I sistemi di IA devono utilizzare algoritmi che producono risultati comprensibili, evitando "scatole nere" inaccessibili.
- **Spiegazioni Chiare**: Le decisioni dell'IA devono essere accompagnate da spiegazioni intuitive, come visualizzazioni o linguaggio naturale.

2.3.2 Implicazioni Pratiche

- **Fiducia e Accettazione**: La trasparenza è essenziale per costruire fiducia nell'IA, favorendone l'adozione da parte del pubblico.
- Responsabilità: La spiegabilità facilita la tracciabilità delle decisioni, permettendo di identificare e correggere errori.

2.3.3 Azioni Necessarie

- **Standard di Trasparenza**: Devono essere definiti standard chiari per la trasparenza e la spiegabilità dei sistemi di IA.
- **Strumenti di Visualizzazione**: Gli sviluppatori devono creare strumenti che rendano comprensibili i processi decisionali dell'IA.

2.4 Equità e Non Discriminazione

L'equità e la non discriminazione sono principi fondamentali per garantire che l'IA non perpetui o amplifichi disuguaglianze esistenti.

2.4.1 Identificazione e Correzione dei Bias

- **Dati di Addestramento**: I dati utilizzati per addestrare i sistemi di IA devono essere rappresentativi e privi di bias.
- **Algoritmi Imparziali**: Gli algoritmi devono essere progettati per evitare discriminazioni basate su genere, etnia, età o altre caratteristiche personali.

2.4.2 Implicazioni Pratiche

- **Giustizia Sociale**: Senza equità, l'IA può amplificare disuguaglianze, creando ingiustizie sociali ed economiche.
- **Conformità Legale**: La non discriminazione è essenziale per garantire il rispetto delle leggi e dei regolamenti.

2.4.3 Azioni Necessarie

- Audit dei Dati: I dati di addestramento devono essere sottoposti a audit regolari per identificare e correggere bias.
- **Test di Imparzialità**: I sistemi di IA devono essere testati per garantire che non producano decisioni discriminatorie.

2.5 Privacy e Protezione dei Dati

La privacy e la protezione dei dati sono essenziali per garantire che i dati personali siano gestiti in modo sicuro e trasparente.

2.5.1 Minimizzazione dei Dati

- **Raccolta Limitata**: I dati personali devono essere raccolti solo quando strettamente necessario e per scopi specifici.
- **Consenso Informato**: Gli utenti devono essere informati su come i loro dati verranno utilizzati e devono dare il loro consenso esplicito.

2.5.2 Implicazioni Pratiche

- **Protezione dei Diritti**: La privacy è un diritto fondamentale che deve essere rispettato in ogni fase del ciclo di vita dell'IA.
- Fiducia del Pubblico: La protezione dei dati è essenziale per costruire fiducia nell'IA.

2.5.3 Azioni Necessarie

- Conformità al GDPR: I sistemi di IA devono rispettare il Regolamento Generale sulla Protezione dei Dati (GDPR) e altre normative sulla privacy.
- **Sicurezza dei Dati**: I dati personali devono essere protetti da accessi non autorizzati e violazioni.

2.6 Benessere Sociale e Ambientale

L'IA deve contribuire al benessere della società e alla sostenibilità ambientale, promuovendo equità e riducendo gli impatti negativi.

2.6.1 Impatto Sociale

- **Equità e Inclusione**: L'IA deve essere utilizzata per promuovere equità e inclusione, migliorando la qualità della vita per tutti.
- **Riduzione delle Disuguaglianze**: L'IA può essere uno strumento per ridurre le disuguaglianze sociali ed economiche.

2.6.2 Impatto Ambientale

• **Sostenibilità**: L'IA deve essere progettata per minimizzare il consumo energetico e l'impatto ambientale, ad esempio ottimizzando l'efficienza dei data center.

2.6.3 Azioni Necessarie

- **Valutazioni di Impatto**: Ogni sistema di IA deve essere sottoposto a valutazioni di impatto sociale e ambientale.
- **Incentivi per la Sostenibilità**: Devono essere creati incentivi per promuovere lo sviluppo di IA sostenibile.

2.7 Responsabilità e Tracciabilità

La responsabilità e la tracciabilità sono essenziali per garantire che gli sviluppatori e gli operatori dell'IA siano responsabili delle loro creazioni.

2.7.1 Meccanismi di Responsabilità

- **Tracciabilità delle Decisioni**: Le decisioni dell'IA devono essere registrate e tracciabili, permettendo di identificare e correggere errori.
- **Accountability**: Devono esistere meccanismi chiari per garantire che gli sviluppatori e gli operatori siano responsabili delle loro azioni.

2.7.2 Implicazioni Pratiche

- **Correzione degli Errori**: La tracciabilità facilita la correzione degli errori e il miglioramento continuo dei sistemi di IA.
- **Conformità Legale**: La responsabilità è essenziale per garantire il rispetto delle leggi e dei regolamenti.

2.7.3 Azioni Necessarie

- **Registri Dettagliati**: I sistemi di IA devono generare log chiari e completi che documentino le decisioni e i processi.
- **Audit Indipendenti**: Devono essere condotti audit regolari per verificare il rispetto dei principi etici.

3. Verifica del Codice: Garantire Sicurezza Etica e Decisionale

Uno degli aspetti più critici per garantire un'IA etica e human-centric è la **verifica del codice**. Il codice che alimenta i sistemi di IA deve essere progettato e testato per garantire che rispetti i principi etici e affronti le sfide pratiche descritte in questo manifesto.

3.1 Elementi di Sicurezza nel Codice

Il codice dei sistemi di IA deve includere meccanismi specifici per garantire che le decisioni siano sicure, trasparenti e allineate ai valori umani. Di seguito, approfondiamo i quattro elementi chiave che devono essere integrati nel codice.

3.1.1 Robustezza Tecnica

La robustezza tecnica è fondamentale per garantire che i sistemi di IA siano resistenti a errori, manipolazioni e attacchi informatici. Questo elemento include:

- **Resistenza agli Errori**: Il codice deve essere progettato per gestire situazioni impreviste, come input anomali o dati corrotti, senza produrre risultati errati o dannosi.
- **Protezione dagli Attacchi**: I sistemi di IA devono essere protetti da attacchi informatici, come il *data poisoning* (manipolazione dei dati di addestramento) o gli *adversarial attacks* (input progettati per ingannare l'IA).
- **Continuità del Servizio**: Il codice deve garantire che il sistema continui a funzionare correttamente anche in condizioni di stress o sotto carico elevato.

Senza robustezza tecnica, i sistemi di IA possono fallire in situazioni critiche, come quelle mediche o di sicurezza, con conseguenze potenzialmente disastrose.

3.1.2 Controlli Etici Integrati

I controlli etici integrati sono meccanismi progettati per prevenire decisioni discriminatorie, dannose o non allineate ai valori umani. Questo include:

- **Rilevazione dei Bias**: Il codice deve includere strumenti per identificare e correggere bias nei dati di addestramento e nei processi decisionali.
- **Limitazione delle Decisioni**: I sistemi di IA devono essere configurati per evitare decisioni estreme o pericolose, come quelle che potrebbero violare i diritti umani.
- **Allineamento ai Valori Umani**: Il codice deve incorporare principi etici, come il rispetto della privacy, l'equità e la non discriminazione, in ogni fase del processo decisionale.

Senza controlli etici, i sistemi di IA possono perpetuare discriminazioni o prendere decisioni dannose, minando la fiducia del pubblico e causando danni sociali.

3.1.3 Tracciabilità delle Decisioni

La tracciabilità è essenziale per garantire che le decisioni dell'IA possano essere ricostruite e verificate. Questo elemento include:

- **Registri Dettagliati**: Il codice deve generare log chiari e completi che documentino come e perché una decisione è stata presa.
- **Identificazione delle Fonti**: Le decisioni devono essere collegabili ai dati e ai processi che le hanno generate, permettendo di risalire all'origine di eventuali errori o bias.
- Auditabilità: Il codice deve essere progettato per facilitare audit esterni, permettendo a terze parti di verificare il rispetto dei principi etici.

Senza tracciabilità, è impossibile identificare e correggere errori o bias, rendendo i sistemi di IA opachi e difficili da regolamentare.

3.1.4 Spiegabilità

La spiegabilità è la capacità di rendere comprensibili i processi decisionali dell'IA, anche per utenti non tecnici. Questo elemento include:

- Modelli Interpretabili: Il codice deve utilizzare algoritmi che producono risultati comprensibili, evitando "scatole nere" inaccessibili.
- Spiegazioni Chiare: I sistemi di IA devono fornire spiegazioni intuitive delle loro decisioni, ad esempio attraverso visualizzazioni o linguaggio naturale.
- **Interazione Umana**: Il codice deve facilitare l'interazione tra l'IA e gli utenti, permettendo a questi ultimi di porre domande e ottenere risposte chiare.

Senza spiegabilità, gli utenti non possono fidarsi dei sistemi di IA, limitandone l'adozione e aumentando il rischio di decisioni errate o dannose.

3.2 Processi di Verifica Indipendenti

Per garantire che i sistemi di lA rispettino i principi etici e di sicurezza, è essenziale istituire **processi di verifica indipendenti**. Questi processi devono essere condotti da organismi terzi, privi di conflitti di interesse, e devono includere audit regolari, certificazioni e linee guida chiare per gli sviluppatori. Di seguito, approfondiamo i componenti chiave di questi processi.

3.2.1 Audit Regolari

Gli audit regolari sono fondamentali per garantire che i sistemi di IA rispettino i principi etici e di sicurezza nel tempo. Questi audit devono essere condotti da esperti indipendenti e devono coprire tutti gli aspetti del sistema, dal codice ai dati di addestramento.

Gli audit regolari servono a identificare potenziali violazioni dei principi etici, come bias, discriminazioni o mancanza di trasparenza. Devono essere condotti periodicamente e in modo approfondito, utilizzando metodologie standardizzate.

- Frequenza: Gli audit devono essere condotti almeno una volta all'anno o dopo ogni aggiornamento significativo del sistema.
- Metodologie Standardizzate: Devono essere utilizzati protocolli riconosciuti a livello internazionale per garantire coerenza e affidabilità.
- **Copertura Completa**: Gli audit devono coprire tutti gli aspetti del sistema, inclusi dati, algoritmi, interfacce e processi decisionali.
- **Report Chiari**: I risultati degli audit devono essere documentati in report dettagliati, accessibili alle autorità competenti e al pubblico.

3.2.2 Certificazioni Etiche

Le certificazioni etiche sono un modo per riconoscere pubblicamente i sistemi di IA che rispettano i principi etici e di sicurezza. Queste certificazioni devono essere rilasciate da organismi indipendenti e devono essere basate su criteri rigorosi.

Le certificazioni etiche servono a costruire fiducia nel pubblico e a incentivare le aziende a sviluppare sistemi di IA responsabili. Devono essere basate su standard chiari e devono essere rinnovate periodicamente.

- **Criteri Rigorosi**: Le certificazioni devono essere basate su criteri chiari e misurabili, come l'assenza di bias, la trasparenza e la sicurezza.
- **Organismi Indipendenti**: Le certificazioni devono essere rilasciate da organismi privi di conflitti di interesse.
- **Rinnovo Periodico**: Le certificazioni devono essere rinnovate periodicamente per garantire che i sistemi continuino a rispettare i principi etici.
- **Pubblicità**: Le aziende certificate devono poter utilizzare un logo o un marchio riconoscibile per comunicare il loro impegno etico.

3.2.3 Linee Guida per gli Sviluppatori

Le linee guida per gli sviluppatori sono essenziali per garantire che i principi etici siano integrati fin dalle prime fasi dello sviluppo dell'IA. Queste linee guida devono essere chiare, pratiche e basate su esempi concreti.

Le linee guida servono a orientare gli sviluppatori nella progettazione e implementazione di sistemi di IA etici. Devono coprire tutti gli aspetti dello sviluppo, dalla raccolta dei dati alla progettazione degli algoritmi.

- **Esempi Pratici**: Le linee guida devono includere esempi concreti di come integrare i principi etici nel codice.
- **Strumenti e Risorse**: Devono essere forniti strumenti e risorse, come librerie software e checklist, per facilitare l'implementazione.
- **Formazione**: Gli sviluppatori devono essere formati sull'uso delle linee guida e sui principi etici dell'IA.
- **Aggiornamenti Regolari**: Le linee guida devono essere aggiornate regolarmente per riflettere le nuove sfide e tecnologie.

3.2.4 Coinvolgimento delle Parti Interessate

Il coinvolgimento delle parti interessate, come cittadini, organizzazioni della società civile e autorità pubbliche, è essenziale per garantire che i processi di verifica riflettano le esigenze e i valori della società.

Il coinvolgimento delle parti interessate serve a garantire che i processi di verifica siano inclusivi e rappresentativi. Questo approccio promuove la trasparenza e la fiducia del pubblico.

• **Panel Civici**: Devono essere istituiti panel civici per coinvolgere i cittadini nella definizione delle regole e delle politiche sull'IA.

- **Consultazioni Pubbliche**: Devono essere organizzate consultazioni pubbliche per raccogliere feedback e suggerimenti.
- Rappresentanza Equilibrata: Le parti interessate devono includere rappresentanti di diverse comunità, inclusi gruppi vulnerabili.
- **Trasparenza**: I risultati delle consultazioni devono essere pubblicati e resi accessibili al pubblico.

3.2.5 Collaborazione Internazionale

La collaborazione internazionale è essenziale per garantire che i processi di verifica siano armonizzati a livello globale e per promuovere standard etici comuni.

La collaborazione internazionale serve a evitare frammentazione e concorrenza sleale, promuovendo un approccio coordinato alla regolamentazione dell'IA. Questo include la condivisione di best practice e la creazione di standard globali.

- **Forum Internazionali**: Devono essere istituiti forum internazionali per discutere e armonizzare le regolamentazioni.
- **Standard Globali**: Devono essere sviluppati standard globali per la verifica e la certificazione dei sistemi di IA.
- **Condivisione di Risorse**: I paesi devono condividere risorse, come strumenti di audit e linee guida, per facilitare l'implementazione.
- **Accordi di Collaborazione**: Devono essere stipulati accordi di collaborazione tra paesi e organizzazioni internazionali.

3.3 La Minaccia dell'Accelerazionismo

L'accelerazionismo nello sviluppo dell'IA, alimentato dalla corsa tra superpotenze per il dominio tecnologico, rappresenta una delle maggiori minacce alla sicurezza etica e decisionale dei sistemi di IA. Questo approccio, focalizzato sulla velocità e sulla competizione, riduce drasticamente la possibilità che i processi di sicurezza e i principi etici siano adeguatamente sviluppati e implementati. Di seguito, approfondiamo i rischi e le azioni necessarie per contrastare questa tendenza.

3.3.1 Rischi dell'Accelerazionismo

L'accelerazionismo porta a un rilascio prematuro di sistemi di IA, spesso senza adeguati controlli di sicurezza e etici. Questo approccio può avere conseguenze disastrose per la società e i diritti umani.

La pressione per essere i primi a mercato spinge le aziende e i governi a trascurare gli aspetti etici e di sicurezza, rilasciando sistemi di IA che non sono stati adeguatamente testati o validati. Questo aumenta il rischio di errori, violazioni della privacy e discriminazioni.

- Rilascio Prematuro: I sistemi di IA vengono rilasciati prima di essere completamente testati, aumentando il rischio di errori e decisioni dannose.
 - Senza test approfonditi, i sistemi di IA possono produrre risultati imprevedibili o pericolosi, specialmente in contesti critici come la sanità o la sicurezza.
- Mancanza di Controlli Etici: Gli aspetti etici, come la trasparenza e la non discriminazione, vengono spesso trascurati per accelerare lo sviluppo. Questo porta a sistemi che perpetuano bias o violano i diritti fondamentali, minando la fiducia del pubblico.
- **Sicurezza Compromessa**: La fretta nello sviluppo può portare a vulnerabilità tecniche, esponendo i sistemi di IA ad attacchi informatici. Sistemi non sicuri possono essere manipolati da attori malevoli, con conseguenze potenzialmente disastrose.

3.3.2 Concorrenza Sleale e Mancanza di Standard

La corsa tra superpotenze crea un ambiente in cui la concorrenza sleale prevale sulla collaborazione, rendendo difficile l'adozione di standard etici e di sicurezza comuni.

La competizione per il dominio tecnologico spinge i paesi e le aziende a ignorare gli standard etici e di sicurezza, privilegiando la velocità e l'efficienza. Questo crea un ambiente in cui chi rispetta le regole è svantaggiato.

- Divergenza negli Standard: I paesi adottano approcci diversi alla regolamentazione dell'IA, creando frammentazione e incoerenza, ma senza standard comuni, è difficile garantire che i sistemi di IA rispettino i principi etici a livello globale.
- Concorrenza Basata sulla Velocità: Le aziende sono incentivate a rilasciare prodotti rapidamente, spesso a scapito della qualità e della sicurezza. Questo approccio favorisce chi ignora i controlli etici, creando un mercato distorto.

 Mancanza di Collaborazione: La competizione tra superpotenze riduce la possibilità di collaborazione internazionale su questioni etiche e di sicurezza. Senza collaborazione, è difficile sviluppare soluzioni globali alle sfide dell'IA.

3.3.3 Impatto sulla Sicurezza Etica e Decisionale

L'accelerazionismo compromette la sicurezza etica e decisionale dei sistemi di IA, aumentando il rischio di decisioni dannose o discriminatorie.

La fretta nello sviluppo riduce la possibilità di integrare controlli etici e di sicurezza nel codice, aumentando il rischio che i sistemi di IA prendano decisioni dannose o violino i diritti umani.

- Decisioni Non Allineate ai Valori Umani: I sistemi di IA possono
 prendere decisioni che non rispettano i diritti fondamentali o i valori etici.
 Questo è particolarmente problematico in contesti come la giustizia o
 l'assistenza sanitaria, dove le decisioni hanno un impatto diretto sulle
 persone.
- Aumento dei Bias e delle Discriminazioni: La mancanza di controlli etici aumenta il rischio che i sistemi di IA perpetuino bias e discriminazioni, ciò può portare a ingiustizie sociali ed economiche, amplificando le disuguaglianze esistenti.
- Riduzione della Trasparenza: L'accelerazionismo spesso porta a sistemi di IA opachi, difficili da comprendere o verificare. Senza trasparenza, è impossibile garantire che le decisioni dell'IA siano giuste e responsabili.

3.3.4 Azioni Necessarie per Contrastare l'Accelerazionismo

Per contrastare l'accelerazionismo, è essenziale adottare un approccio globale e coordinato, che promuova la collaborazione e la responsabilità.

Le azioni necessarie includono la creazione di standard internazionali, la promozione della collaborazione tra paesi e l'adozione di politiche che incentivino lo sviluppo etico dell'IA.

- **Standard Internazionali**: Devono essere sviluppati standard globali per la sicurezza e l'etica dell'IA, tali standard devono essere adottati da tutti i paesi e le aziende, garantendo coerenza e responsabilità.
- **Collaborazione Globale**: I paesi devono collaborare per affrontare le sfide dell'IA in modo coordinato, ciò include la condivisione di best practice, risorse e strumenti per lo sviluppo etico dell'IA.

- Incentivi per lo Sviluppo Etico: I governi devono creare incentivi per le aziende che sviluppano sistemi di IA etici e sicuri, includendo finanziamenti, agevolazioni fiscali o priorità negli appalti pubblici.
- **Educazione e Consapevolezza**: È essenziale promuovere l'educazione e la consapevolezza sui rischi dell'accelerazionismo con programmi di formazione per sviluppatori, decisori politici e cittadini

4. Le Azioni Concrete per un'IA Etica e Human-Centric

Per tradurre i principi etici in pratica e garantire che l'IA sia sviluppata e utilizzata in modo responsabile, è necessario adottare un piano d'azione concreto e strutturato. Questo piano si articola in quattro pilastri principali, ciascuno dei quali include azioni specifiche e responsabilità chiare. Di seguito, approfondiamo ciascun pilastro con descrizioni dettagliate e sottoparagrafi esplicativi.

4.1 Un Quadro Normativo Completo

Un quadro normativo completo è essenziale per garantire che i sistemi di IA rispettino i principi etici e di sicurezza. Questo quadro deve includere regolamenti vincolanti, standard tecnici e meccanismi di certificazione.

4.1.1 Regolamenti Vincolanti

I regolamenti devono essere legalmente vincolanti e applicabili a tutti i sistemi di IA, indipendentemente dal settore o dal contesto di utilizzo. Devono coprire aspetti come la supervisione umana, la trasparenza, la non discriminazione e la protezione dei dati.

Definizione Chiara dei Requisiti: I regolamenti devono specificare in modo chiaro i requisiti etici e di sicurezza che i sistemi di IA devono rispettare.

Meccanismi di Applicazione: Devono essere istituiti organismi di controllo incaricati di far rispettare i regolamenti e di sanzionare le violazioni.

Aggiornamenti Periodici: I regolamenti devono essere aggiornati regolarmente per tenere conto delle nuove tecnologie e delle sfide emergenti.

4.1.2 Standard Tecnici

Gli standard tecnici sono essenziali per garantire che i sistemi di IA siano progettati e implementati in modo coerente e sicuro. Questi standard devono coprire aspetti come la robustezza tecnica, la trasparenza degli algoritmi e la gestione dei dati.

Standard Globali: Gli standard devono essere sviluppati in collaborazione con organizzazioni internazionali per garantire coerenza a livello globale.

Adozione Obbligatoria: Gli standard devono essere adottati obbligatoriamente da tutti gli sviluppatori e operatori di IA.

Strumenti di Supporto: Devono essere forniti strumenti e risorse per aiutare gli sviluppatori a conformarsi agli standard.

4.1.3 Certificazioni Etiche

Le certificazioni etiche sono un modo per riconoscere pubblicamente i sistemi di IA che rispettano i principi etici e di sicurezza. Queste certificazioni devono essere rilasciate da organismi indipendenti e basate su criteri rigorosi.

Criteri Chiari: Le certificazioni devono essere basate su criteri chiari e misurabili, come l'assenza di bias, la trasparenza e la sicurezza.

Processo di Verifica: Le certificazioni devono essere rilasciate solo dopo un processo di verifica indipendente e approfondito.

Pubblicità: Le aziende certificate devono poter utilizzare un logo o un marchio riconoscibile per comunicare il loro impegno etico.

4.2 Collaborazione Globale

La collaborazione globale è essenziale per garantire che i principi etici e di sicurezza siano rispettati a livello internazionale. Questo pilastro include la creazione di forum internazionali, lo sviluppo di standard globali e la condivisione di risorse.

4.2.1 Forum Internazionali

I forum internazionali sono piattaforme per discutere e armonizzare le regolamentazioni sull'IA. Questi forum devono coinvolgere rappresentanti di governi, aziende, organizzazioni della società civile e esperti.

Partecipazione Inclusiva: I forum devono includere rappresentanti di tutti i paesi e le comunità, garantendo che le decisioni riflettano le esigenze globali.

Agenda Chiara: I forum devono avere un'agenda chiara e focalizzata su questioni specifiche, come la sicurezza, la trasparenza e la non discriminazione.

Risultati Tangibili: I forum devono produrre risultati tangibili, come accordi internazionali o linee guida comuni.

4.2.2 Standard Globali

Gli standard globali sono essenziali per garantire coerenza e responsabilità nello sviluppo e nell'uso dell'IA. Questi standard devono coprire aspetti come la sicurezza, la trasparenza e la protezione dei dati.

Sviluppo Collaborativo: Gli standard devono essere sviluppati in collaborazione con organizzazioni internazionali, governi e aziende.

Adozione Obbligatoria: Gli standard devono essere adottati obbligatoriamente da tutti i paesi e le aziende.

Monitoraggio e Aggiornamento: Gli standard devono essere monitorati e aggiornati regolarmente per tenere conto delle nuove tecnologie e delle sfide emergenti.

4.2.3 Condivisione di Risorse

La condivisione di risorse, come strumenti di audit, linee guida e best practice, è essenziale per facilitare l'implementazione dei principi etici e di sicurezza.

Piattaforme di Condivisione: Devono essere create piattaforme online per condividere risorse e strumenti tra paesi e organizzazioni.

Formazione e Supporto: Devono essere forniti programmi di formazione e supporto per aiutare gli sviluppatori e i decisori politici a utilizzare le risorse.

Accesso Aperto: Le risorse devono essere accessibili a tutti, garantendo che anche i paesi in via di sviluppo possano beneficiarne.

4.3 Educazione e Consapevolezza

L'educazione e la consapevolezza sono essenziali per garantire che tutti gli attori coinvolti nello sviluppo e nell'uso dell'IA comprendano i principi etici e di sicurezza. Questo pilastro include programmi di formazione, campagne di sensibilizzazione e iniziative per il pubblico.

4.3.1 Programmi di Formazione

I programmi di formazione devono essere sviluppati per educare gli sviluppatori, i decisori politici e i cittadini sui principi etici e di sicurezza dell'IA.

Contenuti Completi: I programmi di formazione devono coprire tutti gli aspetti dell'IA, dalla progettazione all'implementazione.

Accessibilità: I programmi di formazione devono essere accessibili a tutti, inclusi i paesi in via di sviluppo.

Aggiornamenti Regolari: I programmi di formazione devono essere aggiornati regolarmente per riflettere le nuove tecnologie e le sfide emergenti.

4.3.2 Campagne di Sensibilizzazione

Le campagne di sensibilizzazione devono essere lanciate per aumentare la consapevolezza del pubblico sui rischi e le opportunità dell'IA.

Messaggi Chiari: Le campagne devono utilizzare messaggi chiari e comprensibili per raggiungere un pubblico ampio.

Coinvolgimento del Pubblico: Le campagne devono coinvolgere il pubblico attraverso eventi, workshop e discussioni.

Valutazione dell'Impatto: L'efficacia delle campagne deve essere valutata regolarmente per garantire che raggiungano gli obiettivi prefissati.

4.3.3 Iniziative per il Pubblico

Le iniziative per il pubblico, come panel civici e consultazioni, sono essenziali per garantire che le decisioni sull'IA riflettano i valori e le esigenze della società.

Partecipazione Inclusiva: Le iniziative devono coinvolgere rappresentanti di tutte le comunità, inclusi gruppi vulnerabili.

Trasparenza: I risultati delle iniziative devono essere pubblicati e resi accessibili al pubblico.

Impatto sulle Politiche: Le iniziative devono avere un impatto tangibile sulle politiche e le regolamentazioni sull'IA.

4.4 Partecipazione Pubblica

La partecipazione pubblica è essenziale per garantire che le decisioni sull'IA riflettano i valori e le esigenze della società. Questo pilastro include la creazione di panel civici, consultazioni pubbliche e meccanismi di feedback.

4.4.1 Panel Civici

I panel civici sono gruppi di cittadini incaricati di discutere e fornire feedback sulle politiche e le regolamentazioni sull'IA.

Rappresentanza Equilibrata: I panel devono includere rappresentanti di tutte le comunità, garantendo che le decisioni riflettano le esigenze globali.

Formazione Adeguata: I partecipanti devono essere formati sui principi etici e di sicurezza dell'IA.

Impatto sulle Decisioni: I feedback dei panel devono avere un impatto tangibile sulle decisioni politiche.

4.4.2 Consultazioni Pubbliche

Le consultazioni pubbliche sono processi per raccogliere feedback e suggerimenti dai cittadini sulle politiche e le regolamentazioni sull'IA.

Accessibilità: Le consultazioni devono essere accessibili a tutti, inclusi i cittadini con disabilità o con limitato accesso alla tecnologia.

Trasparenza: I risultati delle consultazioni devono essere pubblicati e resi accessibili al pubblico.

Risposte Concrete: I decisori politici devono rispondere ai feedback ricevuti, spiegando come sono stati integrati nelle decisioni.

4.4.3 Meccanismi di Feedback

I meccanismi di feedback sono strumenti per raccogliere e analizzare le opinioni del pubblico sull'uso e l'impatto dell'IA.

Facilità d'Uso: I meccanismi di feedback devono essere facili da usare e accessibili a tutti.

Analisi dei Dati: I feedback raccolti devono essere analizzati per identificare tendenze e problemi comuni.

Risposte Tempestive: I decisori politici devono rispondere ai feedback in modo tempestivo, dimostrando che le opinioni del pubblico sono prese in considerazione.

5. Un Appello all'Azione

Il futuro dell'IA dipende dalle decisioni che prendiamo oggi. Senza un'azione tempestiva, rischiamo di creare sistemi che minacciano i diritti umani, amplificano disuguaglianze e compromettono la sicurezza delle nostre società.

Chiediamo alle autorità accademiche, politiche e istituzionali di unirsi a noi in questo impegno. Firmando questo manifesto, vi impegnate a:

- 1. Promuovere un'IA etica e human-centric.
- 2. Sostenere l'adozione di un quadro normativo completo che includa controlli sulla sicurezza etica e decisionale.
- 3. Collaborare a livello globale per garantire che l'IA sia sviluppata e utilizzata in modo responsabile.

L'Unione Europea ha l'opportunità di essere un leader globale nell'etica dell'IA. Agiamo ora per garantire che l'IA sia una forza positiva per l'umanità.

6. Conclusione

L'IA è una tecnologia potente, ma il suo impatto dipende da come la sviluppiamo e la utilizziamo. Questo manifesto rappresenta un appello all'azione per garantire che l'IA sia al servizio dell'umanità, rispettando i diritti fondamentali e promuovendo il benessere sociale.

Unitevi a noi in questo impegno. Insieme, possiamo costruire un futuro in cui l'IA sia etica, trasparente e human-centric.

Firmato,

[Le autorità accademiche, politiche e istituzionali che aderiscono al manifesto]